2021

파이썬, R을 활용한 빅데이터 시각화 구현

CAVITIES

(충 치)

Medical
Presentation

김태우

INDEX

개요

주제 및 목적

일정관리

개발환경

목표설정

주제 & 목적

SUBJECT & PURPOSE

Subject :

건강검진 후, **충치 유무**(有無)를 알려주는 친절한 AI

Purpose :

AI, 충치있는 사람은 **구강검진**을 필수항목으로 변경해줘

Pediatrics

일정관리

		계획	완료	8/30		8/31		9/1		9/2		9/3	
기획 및 설계	선정 및 요구사항, 일정관리												
	설계, 기능정의, 데이터수집												
서론 및 이론적 배경	연구 배경 및 목적												
	연구 내용 및 방법												
	프로젝트의 구성												
	이론적 배경												
연구 모형 및 조사 설계	연구모형 및 연구가설												
	변수의 조작적 정의 및 측정 항목												
실증 분석 및 결론	자료 수집 및 표본의 특성												
	측정항목의 기술통계분석 및 시각화												
	신뢰도 및 타당성 검증 및 시각화												
	각자에 맞는 데이터분석 및 시각화												
	추가 분석 및 시각화												
테스트 및 수정													

OS	Windows 10 Pro
Language	Python 3.8.8
IDE	Jupyter Notebook 6.3.0
Open Source	Tensorflow, pycaret

첫 번째.

필수사항인 건강검진을 통해,
AI가 충치 유무를 예측

두 번째.

AI의 예측에 따라,
구강검진을 필수사항으로 변경

데이터 수집

자료 출처

자료 수집

자료출처

검진정보

공공데이터포털 (다운로드)

내 용

국민건강보험공단
건강검진대상자 100만명 (2019년)

CAVITIES

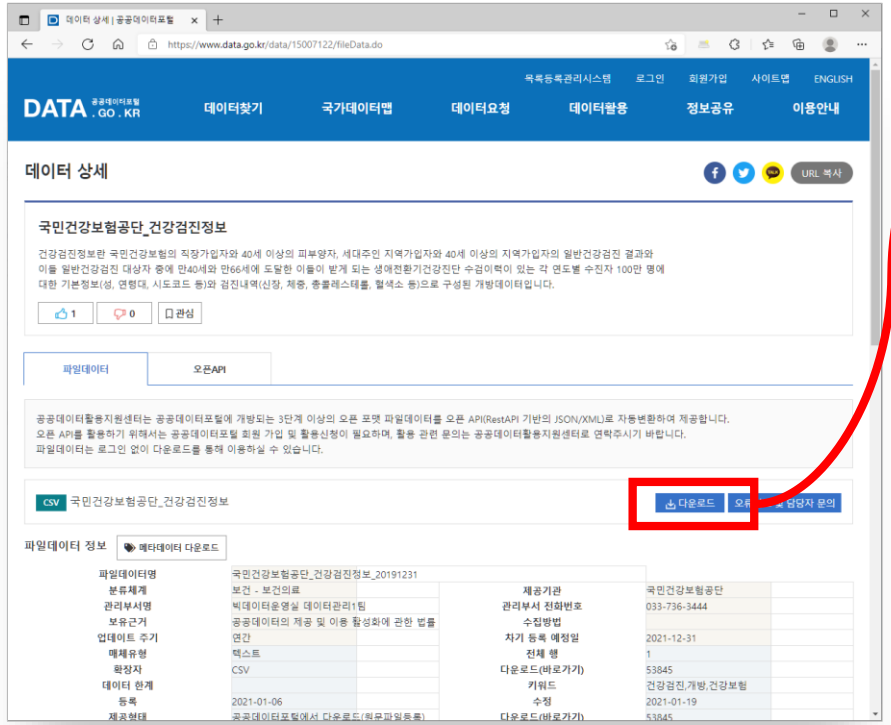


```
raw_data = pd.read_csv("data/국민건강보험공단_건강검진정보_20191231.csv", encoding='cp949')
raw_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000000 entries, 0 to 999999
Data columns (total 34 columns):
 #   Column          Non-Null Count    Dtype
---  ------          --------------    -----
 0   기준년도           1000000 non-null  int64
 1   가입자 일련번호       1000000 non-null  int64
 2   시도코드           1000000 non-null  int64
 3   성별코드           1000000 non-null  int64
 4   연령대 코드(5세단위)   1000000 non-null  int64
 5   신장(5Cm단위)       1000000 non-null  int64
 6   체중(5Kg 단위)      1000000 non-null  int64
 7   허리둘레            999597 non-null   float64
 8   시력(좌)           999805 non-null   float64
 9   시력(우)           999812 non-null   float64
 10  청력(좌)           999819 non-null   float64
 11  청력(우)           999822 non-null   float64
 12  수축기 혈압          994576 non-null   float64
 13  이완기 혈압          994575 non-null   float64
 14  식전혈당(공복혈당)      994477 non-null   float64
 15  총 콜레스테롤         333549 non-null   float64
 16  트리글리세라이드        333544 non-null   float64
 17  HDL 콜레스테롤       333541 non-null   float64
 18  LDL 콜레스테롤       327148 non-null   float64
 19  혈색소             994468 non-null   float64
 20  요단백             989694 non-null   float64
 21  혈청크레아티닌         994474 non-null   float64
 22  (혈청지오티)AST      994478 non-null   float64
 23  (혈청지오티)ALT      994477 non-null   float64
 24  감마 지티피          994470 non-null   float64
 25  흡연상태            999834 non-null   float64
 26  음주여부            644918 non-null   float64
 27  구강검진 수검여부       1000000 non-null  int64
 28  치아우식증유무         397680 non-null   float64
 29  결손치 유무          1000000 non-null  object
 30  치아마모증유무         1000000 non-null  object
 31  제3대구치(사랑니) 이상   1000000 non-null  object
 32  치석              397680 non-null   float64
 33  데이터 공개일자        1000000 non-null  int64
dtypes: float64(22), int64(9), object(3)
memory usage: 259.4+ MB
```

```
raw_data.isnull().sum()
```

```
기준년도                  0
가입자 일련번호              0
시도코드                  0
성별코드                  0
연령대 코드(5세단위)           0
신장(5Cm단위)              0
체중(5Kg 단위)             0
허리둘레                403
시력(좌)               195
시력(우)               188
청력(좌)               181
청력(우)               178
수축기 혈압               5424
이완기 혈압               5425
식전혈당(공복혈당)           5523
총 콜레스테롤            666451
트리글리세라이드            666456
HDL 콜레스테롤           666459
LDL 콜레스테롤           672852
혈색소                5532
요단백               10306
혈청크레아티닌              5526
(혈청지오티)AST           5522
(혈청지오티)ALT           5523
감마 지티피               5530
흡연상태                166
음주여부             355082
구강검진 수검여부              0
치아우식증유무            602320
결손치 유무                 0
치아마모증유무                0
제3대구치(사랑니) 이상          0
치석               602320
데이터 공개일자               0
dtype: int64
```

Pediatrics

데이터 전처리

컨텐츠

전처리

Medical
Presentation

Python Contents

Contents

Data Preprocessing

```
raw_data.isnull().sum()
```

```
시도코드                0
성별코드                0
연령대 코드(5세단위)     0
신장(5Cm단위)           0
체중(5Kg 단위)          0
허리둘레                0
시력(좌)                0
시력(우)                0
청력(좌)                0
청력(우)                0
수축기 혈압             0
이완기 혈압             0
식전혈당(공복혈당)      0
총 콜레스테롤           0
트리글리세라이드        0
HDL 콜레스테롤          0
LDL 콜레스테롤          0
혈색소                  0
요단백                  0
혈청크레아티닌          0
(혈청지오티)AST         0
(혈청지오티)ALT         0
감마 지티피             0
흡연상태                0
음주여부                0
치아우식증유무          0
dtype: int64
```

```
raw_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 120424 entries, 0 to 120423
Data columns (total 26 columns):
 #   Column              Non-Null Count   Dtype
---  ------              --------------   -----
 0   시도코드            120424 non-null  int64
 1   성별코드            120424 non-null  int64
 2   연령대 코드(5세단위) 120424 non-null  int64
 3   신장(5Cm단위)       120424 non-null  int64
 4   체중(5Kg 단위)      120424 non-null  int64
 5   허리둘레            120424 non-null  float64
 6   시력(좌)            120424 non-null  float64
 7   시력(우)            120424 non-null  float64
 8   청력(좌)            120424 non-null  float64
 9   청력(우)            120424 non-null  float64
 10  수축기 혈압         120424 non-null  float64
 11  이완기 혈압         120424 non-null  float64
 12  식전혈당(공복혈당)  120424 non-null  float64
 13  총 콜레스테롤       120424 non-null  float64
 14  트리글리세라이드    120424 non-null  float64
 15  HDL 콜레스테롤      120424 non-null  float64
 16  LDL 콜레스테롤      120424 non-null  float64
 17  혈색소              120424 non-null  float64
 18  요단백              120424 non-null  float64
 19  혈청크레아티닌      120424 non-null  float64
 20  (혈청지오티)AST     120424 non-null  float64
 21  (혈청지오티)ALT     120424 non-null  float64
 22  감마 지티피         120424 non-null  float64
 23  흡연상태            120424 non-null  float64
 24  음주여부            120424 non-null  float64
 25  치아우식증유무      120424 non-null  int32
dtypes: float64(20), int32(1), int64(5)
memory usage: 23.4 MB
```

```
raw_data = pd.read_csv("data/국민건강보험공단_건강검진정보_20191231.csv", encoding='cp949')
raw_data = raw_data[raw_data['구강검진 수검여부'] == 1]
raw_data['음주여부'].fillna(0, inplace=True)
raw_data.dropna(how='any', inplace=True)
raw_data = raw_data.loc[:,'시도코드' : '치아우식증유무']
raw_data['치아우식증유무'] = raw_data['치아우식증유무'].astype(int)
raw_data.drop('구강검진 수검여부', axis=1, inplace=True)
raw_data.index = range(raw_data.shape[0])
raw_data.head(1)
```

	시도코드	성별코드	연령대 코드(5세단위)	신장(5Cm단위)	체중(5Kg 단위)	허리둘레	시력(좌)	시력(우)	청력(좌)	청력(우)	...	LDL 콜레스테롤	혈색소	요단백	혈청크레아티닌	(혈청지오티)AST	(혈청지오티)ALT	감마 지티피	흡연상태	음주여부	치아우식증유무
0	41	1	6	175	70	81.3	0.9	1.0	1.0	1.0	...	93.0	13.1	1.0	0.9	14.0	11.0	30.0	2.0	1.0	0

치아우식증유무: 충치유무(有:1 / 無:0)

- 문제점 : 높은 accuracy(정확도)에 비해
  recall(재현률)이 매우 낮음
- 원 인 : 낮은 충치 비율
  (120,424명中 24,100명, 약20%)
- 해 결 : 충치無 20,000명 / 충치有 20,000명 샘플링


```
1 score = model.evaluate(X_test, Y_test, verbose=0)
2 print('model loss :', score[0])
3 print('model accuracy :', score[1])
4 print('model recall : ', score[2])
5 print('model precision :', score[3])
```

```
model loss : 0.49374809861183167
model accuracy : 0.7973040342330933
model recall : 0.0
model precision : 0.0
```

```
1 predict_model(final_ridge)
```

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	Ridge Classifier	0.7988	0.5001	0.0002	1.0000	0.0003	0.0003	0.0118

```
1 predict_model(final_lda)
```

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	Linear Discriminant Analysis	0.7988	0.6087	0.0005	0.6000	0.0010	0.0007	0.0132

Preprocessed Date

```
result_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 40000 entries, 2 to 120421
Data columns (total 26 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   시도코드            40000 non-null  int64
 1   성별코드            40000 non-null  int64
 2   연령대 코드(5세단위)   40000 non-null  int64
 3   신장(5Cm단위)       40000 non-null  int64
 4   체중(5Kg 단위)      40000 non-null  int64
 5   허리둘레            40000 non-null  float64
 6   시력(좌)           40000 non-null  float64
 7   시력(우)           40000 non-null  float64
 8   청력(좌)           40000 non-null  float64
 9   청력(우)           40000 non-null  float64
 10  수축기 혈압          40000 non-null  float64
 11  이완기 혈압          40000 non-null  float64
 12  식전혈당(공복혈당)     40000 non-null  float64
 13  총 콜레스테롤         40000 non-null  float64
 14  트리글리세라이드        40000 non-null  float64
 15  HDL 콜레스테롤       40000 non-null  float64
 16  LDL 콜레스테롤       40000 non-null  float64
 17  혈색소             40000 non-null  float64
 18  요단백             40000 non-null  float64
 19  혈청크레아티닌         40000 non-null  float64
 20  (혈청지오티)AST      40000 non-null  float64
 21  (혈청지오티)ALT      40000 non-null  float64
 22  감마 지티피          40000 non-null  float64
 23  흡연상태            40000 non-null  float64
 24  음주여부            40000 non-null  float64
 25  치아우식증유무         40000 non-null  int64
dtypes: float64(20), int64(6)
memory usage: 8.2 MB
```

```
result_df = pd.read_csv('data/result_df.csv', encoding='utf-8')
result_df_0 = result_df[result_df['치아우식증유무']==0].sample(20000)
result_df_1 = result_df[result_df['치아우식증유무']==1].sample(20000)
result_df = pd.concat([result_df_0, result_df_1])
result_df.sort_index(inplace=True)
print('충치無 :',len(result_df[result_df['치아우식증유무']==0]))
print('충치有 :',len(result_df[result_df['치아우식증유무']==1]))
```

```
충치無 : 20000
충치有 : 20000
```

모델구성 & 학습

Tensorflow

Pycaret

구분 : tensorflow / binary_crossentropy

```
# 독립변수와 타겟변수 분리 & scale 조정 & 학습셋과 테스트셋 분리
Input = result_df.iloc[:, :-1]
Target = result_df.iloc[:,[-1]]
scaler = MinMaxScaler()
scaler.fit(Input)
scaled_input = pd.DataFrame(scaler.transform(Input))
X_train, X_test, Y_train, Y_test = train_test_split(scaled_input, Target, test_size=0.3, random_state=5)

# 모델 구성
model = Sequential()
model.add(Dense(units=1000, input_dim=25, activation='relu'))
model.add(Dense(units=600, activation='relu'))
model.add(Dropout(0.1))
model.add(Dense(units=300, activation='relu'))
model.add(Dense(units=100, activation='relu'))
model.add(Dropout(0.1))
model.add(Dense(units=1, activation='sigmoid'))

# 학습 및 학습과정 그래프
model.compile(loss='binary_crossentropy', optimizer="adam", metrics=['accuracy', metrics.Recall(), metrics.Precision()])
earlyStropping = EarlyStopping(patience=10)
hist = model.fit(X_train, Y_train, epochs=50, batch_size=1000, verbose=1, validation_split=0.3, callbacks=[earlyStropping])

fig, loss_ax = plt.subplots(figsize=(12,8))
loss_ax.plot(hist.history['loss'], 'y', label='train loss')
loss_ax.plot(hist.history['val_loss'], 'g', label='val_loss')
loss_ax.set_xlabel('epochs')
loss_ax.set_ylabel('loss')

acc_ax = loss_ax.twinx()
acc_ax.plot(hist.history['accuracy'], 'b', label='accuracy')
acc_ax.plot(hist.history['val_accuracy'], 'r', label='val_accuracy')
acc_ax.set_ylabel('accuracy')

loss_ax.legend(loc='upper left')
acc_ax.legend(loc='lower left')
plt.show()
```

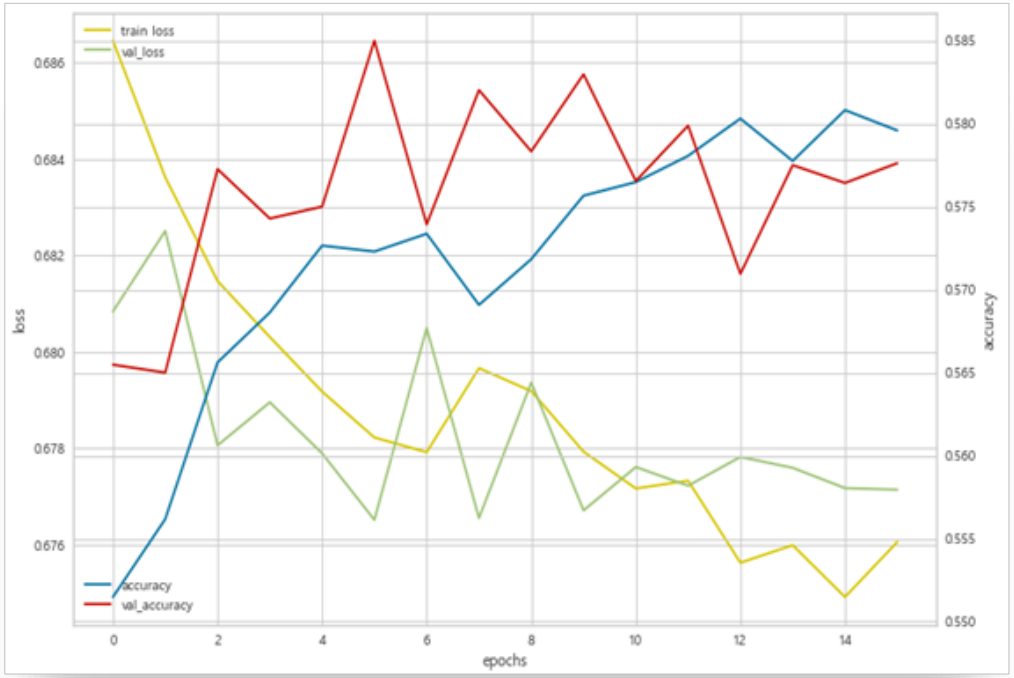

구분 : pycaret / Compare & Create & Tune a Model

```
# 학습셋과 테스트셋 분리
data = result_df.sample(frac=0.95, random_state=786)
data_unseen = result_df.drop(data.index)
data.reset_index(inplace=True, drop=True)
data_unseen.reset_index(inplace=True, drop=True)

# PyCaret 환경설정 및 모델 비교하기
from pycaret.classification import *
exp_clf101 = setup(data = data, target = '치아우식증유무', session_id=123)
best_model = compare_models()
```

```
best_model = compare_models()
```

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	TT (Sec)
lda	Linear Discriminant Analysis	0.5761	0.6039	0.5552	0.5793	0.5670	0.1522	0.1524	0.1970
ridge	Ridge Classifier	0.5759	0.0000	0.5551	0.5791	0.5668	0.1518	0.1519	0.0550
lr	Logistic Regression	0.5743	0.6037	0.5551	0.5772	0.5659	0.1487	0.1488	2.0640
gbc	Gradient Boosting Classifier	0.5697	0.5996	0.5555	0.5715	0.5634	0.1394	0.1394	2.1700
ada	Ada Boost Classifier	0.5682	0.5960	0.5557	0.5699	0.5626	0.1364	0.1365	0.5220
lightgbm	Light Gradient Boosting Machine	0.5645	0.5908	0.5366	0.5681	0.5518	0.1291	0.1293	0.2960
nb	Naive Bayes	0.5575	0.5857	0.3493	0.5983	0.4399	0.1149	0.1265	0.0440
rf	Random Forest Classifier	0.5564	0.5814	0.5320	0.5591	0.5452	0.1127	0.1129	1.7620
et	Extra Trees Classifier	0.5507	0.5738	0.5257	0.5532	0.5390	0.1013	0.1015	1.7700
xgboost	Extreme Gradient Boosting	0.5504	0.5699	0.5405	0.5513	0.5457	0.1008	0.1008	1.9280
catboost	CatBoost Classifier	0.5153	0.5406	0.5011	0.5173	0.5091	0.1306	0.1307	5.9490
dt	Decision Tree Classifier	0.5[illegible]	0.5109	0.5095	0.5108	0.5101	0.0218	0.0218	0.2120
svm	SVM - Linear Kernel	0.5070	0.0000	0.5213	0.5275	0.3793	0.0140	0.0272	0.8240
knn	K Neighbors Classifier	0.5063	0.5[illegible]	0.4994	0.5063	0.5028	0.0127	0.0127	1.3660
qda	Quadratic Discriminant Analysis	0.5038	0.5038	0.61[illegible]	0.5020	0.5408	0.0076	0.0087	0.1530

```
lda = create_model('lda')
```

	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	0.5756	0.6019	0.5519	0.5793	0.5653	0.1511	0.1513
1	0.5797						
2	0.5684						
3	0.5793						
4	0.5714						
5	0.5647						
6	0.5835						
7	0.5782						
8	0.5733						
9	0.5871						
Mean	0.5761						
SD	0.0065						

```
tuned_lda = tune_model(lda)
```

	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	0.5771	0.5998	0.5474	0.5819	0.5641	0.1541	0.1544
1	0.5774	0.6125	0.5662	0.5792	0.5726	0.1549	0.1549
2	0.5699	0.5851	0.5376	0.5748	0.5556	0.1398	0.1401
3	0.5786	0.5973	0.5594	0.5817	0.5703	0.1571	0.1573
4	0.5684	0.6015	0.5556	0.5702	0.5628	0.1368	0.1369
5	0.5692	0.5952	0.5421	0.5731	0.5572	0.1383	0.1385
6	0.5850	0.6054	0.5681	0.5875	0.5777	0.1699	0.1700
7	0.5793	0.6124	0.5561	0.5828	0.5691	0.1586	0.1588
8	0.5748	0.5944	0.5425	0.5796	0.5604	0.1496	0.1499
9	0.5927	0.6298	0.5561	0.5998	0.5771	0.1854	0.1859
Mean	0.5772	0.6033	0.5531	0.5811	0.5667	0.1545	0.1547
SD	0.0071	0.0118	0.0098	0.0079	0.0075	0.0142	0.0143

```
ridge = create_model('ridge')
```

	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	0.5752	0.0000	0.5519	0.5789	0.5651	0.1504	0.1505
1	0.5797						
2	0.5680						
3	0.5789						
4	0.5714						
5	0.5647						
6	0.5827						
7	0.5786						
8	0.5729						
9	0.5867						
Mean	0.5759						
SD	0.0064						

```
tuned_ridge = tune_model(ridge)
```

	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	0.5767	0.0000	0.5534	0.5804	0.5666	0.1534	0.1536
1	0.5801	0.0000	0.5722	0.5814	0.5767	0.1602	0.1602
2	0.5695	0.0000	0.5383	0.5742	0.5557	0.1391	0.1394
3	0.5778	0.0000	0.5632	0.5802	0.5715	0.1556	0.1557
4	0.5711	0.0000	0.5632	0.5722	0.5676	0.1421	0.1421
5	0.5635	0.0000	0.5398	0.5667	0.5529	0.1271	0.1272
6	0.5850	0.0000	0.5673	0.5877	0.5773	0.1699	0.1700
7	0.5767	0.0000	0.5553	0.5797	0.5673	0.1534	0.1535
8	0.5737	0.0000	0.5515	0.5767	0.5638	0.1473	0.1475
9	0.5904	0.0000	0.5568	0.5968	0.5761	0.1809	0.1813
Mean	0.5765	0.0000	0.5561	0.5796	0.5676	0.1529	0.1530
SD	0.0073	0.0000	0.0105	0.0079	0.0080	0.0146	0.0147

구분 : pycaret / lda

```
1 evaluate_model(tuned_lda)
```

Plot Type:

Hyperparameters	AUC	Confusion Matrix	Threshold	Precision Recall
Prediction Error	Class Report	Feature Selection	Learning Curve	Manifold Learning
Calibration Curve	Validation Curve	Dimensions	Feature Importance	Feature Importance...
Decision Boundary	Lift Chart	Gain Chart	Decision Tree	KS Statistic Plot

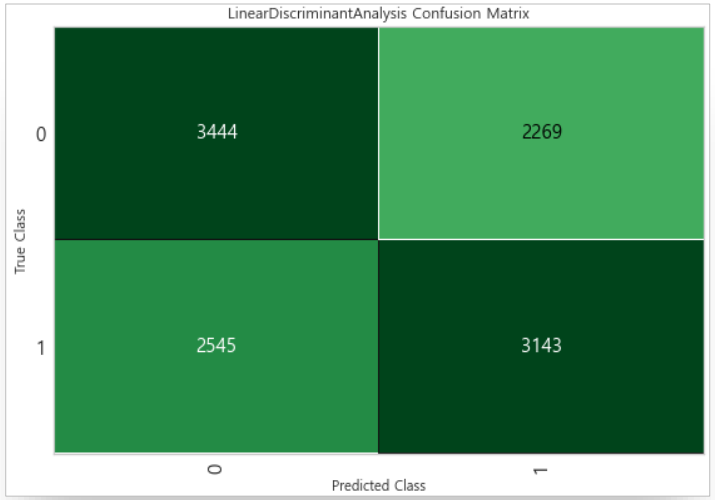

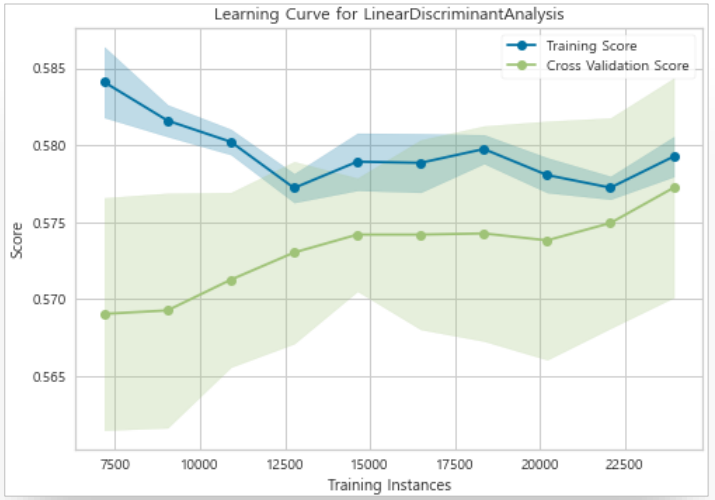

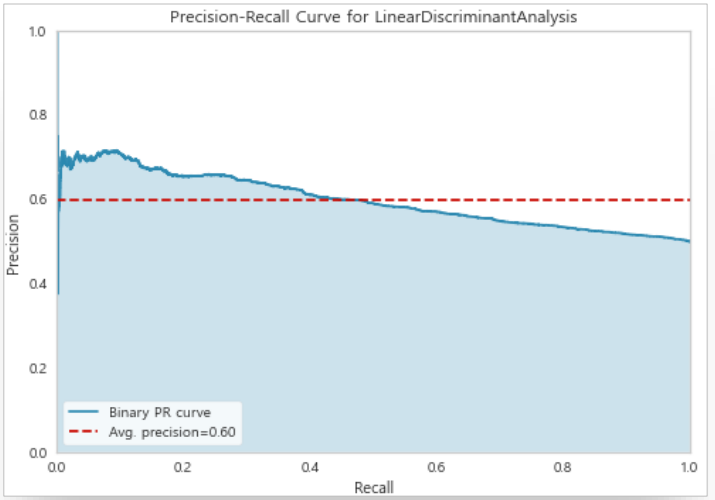

구분 : pycaret / ridge

```
1 evaluate_model(tuned_ridge)
```

Plot Type:

Hyperparameters	AUC	Confusion Matrix	Threshold	Precision Recall
Prediction Error	Class Report	Feature Selection	Learning Curve	Manifold Learning
Calibration Curve	Validation Curve	Dimensions	Feature Importance	Feature Importance...
Decision Boundary	Lift Chart	Gain Chart	Decision Tree	KS Statistic Plot

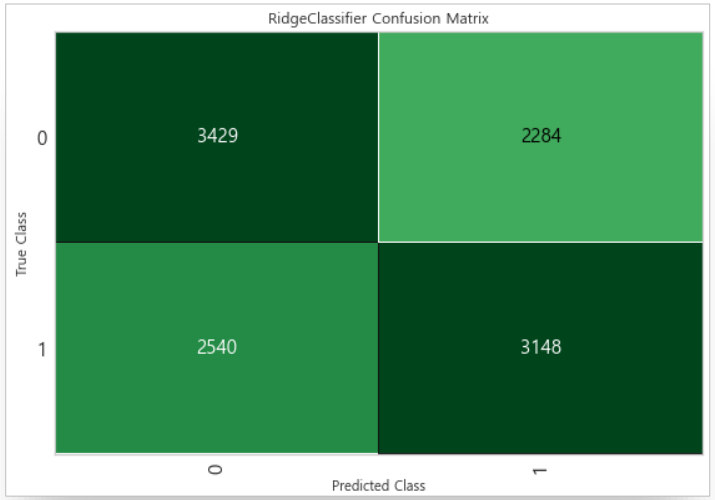

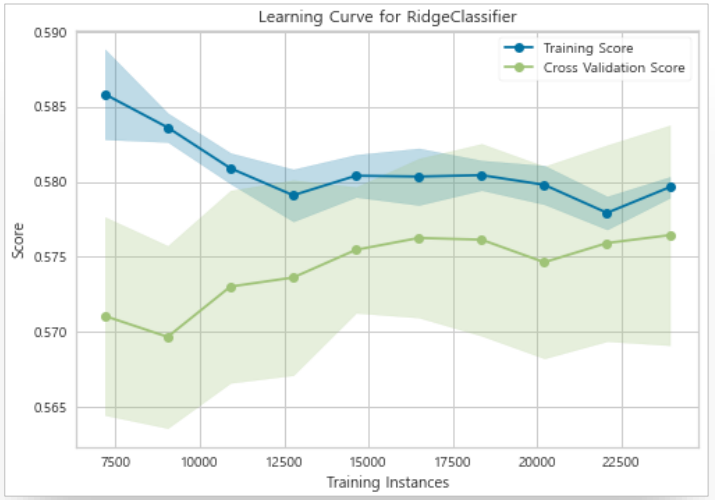

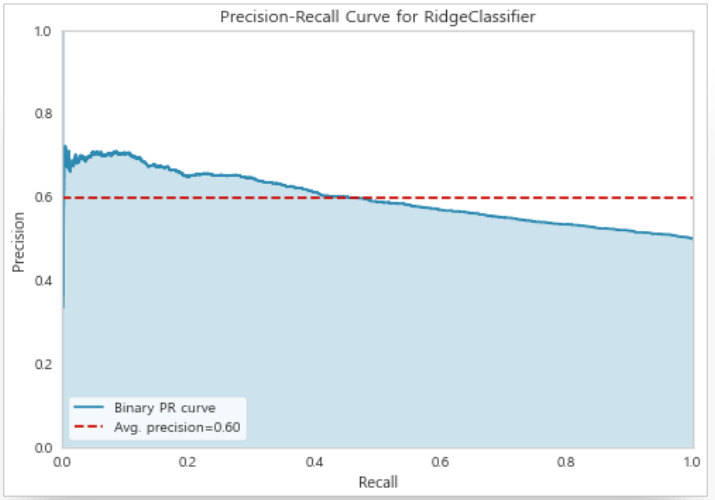

구분 : pycaret / Finalize Model

```
predict_model(tuned_lda);
```

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	Linear Discriminant Analysis	0.5778	0.6052	0.5526	0.5807	0.5663	0.1554	0.1556

```
final_lda = finalize_model(tuned_lda)
```

```
print(final_lda)
```

```
LinearDiscriminantAnalysis(n_components=None, priors=None, shrinkage='auto',
                           solver='lsqr', store_covariance=False, tol=0.0001)
```

```
predict_model(final_lda)
```

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	Linear Discriminant Analysis	0.5799	0.6094	0.5411	0.5854	0.5624	0.1596	0.1600

	체중(5Kg단위)	허리둘레	시력(좌)	시력(우)	수축기혈압	이완기혈압	식전혈당(공복혈당)	총콜레스테롤	트리글리세라이드	HDL콜레스테롤	...	신장(5Cm단위)_180	신장(5Cm단위)_185	신장(5Cm단위)_190	청력(좌)_1.0	청력(우)_1.0	흡연상태_2.0	음주여부_0.0	치아우식증유무	Label	Score
0	55.0	77.5	0.9	1.2	110.0	71.0	98.0	222.0	90.0	51.0	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	1	0.5153
1	90.0	102.0	1.0	0.9	120.0	85.0	111.0	201.0	273.0	39.0	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	1	0.5567
2	70.0	89.0	0.4	0.4	130.0	81.0	305.0	142.0	201.0	30.0	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	0	0.5385
3	75.0	81.0	1.5	1.5	116.0	84.0	86.0	214.0	84.0	52.0	...	0.0	1.0	0.0	1.0	1.0	1.0	0.0	0	1	0.5343
4	50.0	72.0	0.6	0.7	104.0	70.0	83.0	213.0	113.0	56.0	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	0	0.6115
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
11396	65.0	86.0	1.0	1.2	131.0	70.0	86.0	238.0	177.0	56.0	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	1	1	0.6235
11397	75.0	80.0	1.5	1.2	110.0	70.0	96.0	189.0	66.0	54.0	...	0.0	0.0	0.0	1.0	1.0	0.0	1.0	0	1	0.5692
11398	80.0	98.0	0.5	0.7	142.0	72.0	104.0	125.0	196.0	32.0	...	0.0	0.0	0.0	1.0	1.0	1.0	1.0	0	0	0.5523
11399	75.0	79.0	1.0	0.9	138.0	76.0	148.0	162.0	82.0	41.0	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	1	0.5839
11400	65.0	74.0	2.0	2.0	110.0	72.0	98.0	162.0	65.0	69.0	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	1	1	0.5830

11401 rows × 69 columns

```
predict_model(tuned_ridge);
```

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	Ridge Classifier	0.5769	0.5768	0.5534	0.5795	0.5662	0.1537	0.1538

```
final_ridge = finalize_model(tuned_ridge)
```

```
print(final_ridge)
```

```
RidgeClassifier(alpha=9.17, class_weight=None, copy_X=True, fit_intercept=False,
                max_iter=None, normalize=False, random_state=123, solver='auto',
                tol=0.001)
```

```
predict_model(final_ridge)
```

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	Ridge Classifier	0.5791	0.5790	0.5424	0.5842	0.5625	0.1580	0.1584

	체중(5Kg단위)	허리둘레	시력(좌)	시력(우)	수축기혈압	이완기혈압	식전혈당(공복혈당)	총콜레스테롤	트리글리세라이드	HDL콜레스테롤	...	신장(5Cm단위)_175	신장(5Cm단위)_180	신장(5Cm단위)_185	신장(5Cm단위)_190	청력(좌)_1.0	청력(우)_1.0	흡연상태_2.0	음주여부_0.0	치아우식증유무	Label
0	55.0	77.5	0.9	1.2	110.0	71.0	98.0	222.0	90.0	51.0	...	0.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	1
1	90.0	102.0	1.0	0.9	120.0	85.0	111.0	201.0	273.0	39.0	...	0.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	1
2	70.0	89.0	0.4	0.4	130.0	81.0	305.0	142.0	201.0	30.0	...	1.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	0
3	75.0	81.0	1.5	1.5	116.0	84.0	86.0	214.0	84.0	52.0	...	0.0	0.0	1.0	0.0	1.0	1.0	1.0	0.0	0	1
4	50.0	72.0	0.6	0.7	104.0	70.0	83.0	213.0	113.0	56.0	...	0.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
11396	65.0	86.0	1.0	1.2	131.0	70.0	86.0	238.0	177.0	56.0	...	0.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	1	1
11397	75.0	80.0	1.5	1.2	110.0	70.0	96.0	189.0	66.0	54.0	...	1.0	0.0	0.0	0.0	1.0	1.0	0.0	1.0	0	1
11398	80.0	98.0	0.5	0.7	142.0	72.0	104.0	125.0	196.0	32.0	...	0.0	0.0	0.0	0.0	1.0	1.0	1.0	1.0	0	0
11399	75.0	79.0	1.0	0.9	138.0	76.0	148.0	162.0	82.0	41.0	...	1.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0	1
11400	65.0	74.0	2.0	2.0	110.0	72.0	98.0	162.0	65.0	69.0	...	0.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	1	1

11401 rows × 68 columns

결과

Tensorflow

Pycaret

연구의 한계점

구분 : tensorflow

```
score = model.evaluate(X_test, Y_test, verbose=0)
print('model loss :', score[0])
print('model accuracy :', score[1])
print('model recall : ', score[2])
print('model precision :', score[3])
```

```
model loss : 0.6803668737411499
model accuracy : 0.5715833306312561
model recall :  0.5064250230789185
model precision : 0.5890017151832581
```

```
pred = model.predict(X_test)
pred = (pred>0.5)
print(confusion_matrix(Y_test, pred), end='₩n')
print('f1_score : ', f1_score(Y_test, pred))
```

```
[[3785 2145]
 [2996 3074]]
f1_score :  0.5446009389671362
```

구분 : pycaret

```
unseen_predictions = predict_model(final_lda, data=data_unseen)
unseen_predictions.head()
```

	시도코드	성별코드	연령대코드(5세단위)	신장(5Cm단위)	체중(5Kg 단위)	허리둘레	시력(좌)	시력(우)	청력(좌)	청력(우)	...	요단백	혈청크레아티닌	(혈청지오티)AST	(혈청지오티)ALT	감마 지티피	흡연상태	음주여부	치아우식증유무	Label	Score
0	42	1	9	165	90	94.3	0.8	0.5	1.0	1.0	...	1.0	0.9	30.0	46.0	95.0	2.0	1.0	1	1	0.6156
1	41	1	9	175	100	102.0	1.2	1.2	1.0	1.0	...	4.0	1.2	47.0	72.0	55.0	2.0	0.0	0	1	0.5992
2	41	1	10	170	70	85.0	0.7	0.6	1.0	1.0	...	1.0	1.0	26.0	31.0	25.0	2.0	1.0	0	1	0.5278
3	29	1	6	170	80	97.0	1.0	1.5	1.0	1.0	...	1.0	0.8	56.0	118.0	123.0	2.0	1.0	0	1	0.6090
4	48	1	7	175	75	80.0	1.0	1.0	1.0	1.0	...	1.0	1.1	15.0	28.0	20.0	2.0	1.0	1	1	0.6371

5 rows × 28 columns

```
from pycaret.utils import check_metric
check_metric(unseen_predictions['치아우식증유무'], unseen_predictions['Label'], metric = 'Accuracy')
```

Accuracy 0.578

```
unseen_predictions = predict_model(final_ridge, data=data_unseen)
unseen_predictions.head()
```

	시도코드	성별코드	연령대코드(5세단위)	신장(5Cm단위)	체중(5Kg 단위)	허리둘레	시력(좌)	시력(우)	청력(좌)	청력(우)	...	혈색소	요단백	혈청크레아티닌	(혈청지오티)AST	(혈청지오티)ALT	감마 지티피	흡연상태	음주여부	치아우식증유무	Label
0	42	1	9	165	90	94.3	0.8	0.5	1.0	1.0	...	15.6	1.0	0.9	30.0	46.0	95.0	2.0	1.0	1	1
1	41	1	9	175	100	102.0	1.2	1.2	1.0	1.0	...	15.1	4.0	1.2	47.0	72.0	55.0	2.0	0.0	0	1
2	41	1	10	170	70	85.0	0.7	0.6	1.0	1.0	...	15.4	1.0	1.0	26.0	31.0	25.0	2.0	1.0	0	1
3	29	1	6	170	80	97.0	1.0	1.5	1.0	1.0	...	14.6	1.0	0.8	56.0	118.0	123.0	2.0	1.0	0	1
4	48	1	7	175	75	80.0	1.0	1.0	1.0	1.0	...	15.4	1.0	1.1	15.0	28.0	20.0	2.0	1.0	1	1

5 rows × 27 columns

```
from pycaret.utils import check_metric
check_metric(unseen_predictions['치아우식증유무'], unseen_predictions['Label'], metric = 'Accuracy')
```

Accuracy 0.5835

- 충치 치료여부 에 대한 정보 없음
- 낮은 Accuracy(정확도) 와 Precision(정밀도)

Q&A